

Tasa de mortalidad en España por comunidades autónomas

Adrián Carrasco Alcalá^{1,2,†}, Álvaro Nieva Valenzuela^{1,3,†}, Carlos David Llano Chicaiza^{1,4,†}

¹ Universitat de Valencia - Escuela Técnica Superior de Ingeniería (ETSE), Avinguda de l'Universitat, S/N, 46100 Burjassot, Valencia;

² Correo electrónico: acal8@alumni.uv.es;

³ Correo electrónico: alnieva@alumni.uv.es;

⁴ Correo electrónico: cardalla@alumni.uv.es;

* Correspondence: acal8@alumni.uv.es.

† Estos autores contribuyeron por igual a este trabajo.

Simple Summary: Es un trabajo de análisis exploratorio con datos oficiales (INE) para describir cómo varían entre territorios españoles varios indicadores socioeconómicos y de salud (renta, gasto/actividad sanitaria, mortalidad, esperanza de vida) y comprobar si esas diferencias parecen moverse juntas. No busca demostrar causalidad, sino ofrecer una foto comparativa, destacar anomalías (como el corte de 2020 por la COVID-19) y sugerir que factores económicos y de recursos sanitarios pueden estar relacionados con mejores resultados de salud en algunas zonas.

Abstract: Este estudio analiza datos públicos del INE sobre renta, actividad económica sanitaria y tablas de mortalidad para las comunidades autónomas españolas con el fin de describir diferencias territoriales en esperanza de vida y su evolución reciente. Tras limpiar e integrar las fuentes, se observa una mejora general de la esperanza de vida interrumpida en 2020 por la COVID-19 y niveles sistemáticamente más altos en comunidades del centro-norte frente a Ceuta y Melilla. La exploración sugiere que un mayor peso económico del sector sanitario se asocia a menor mortalidad, aunque sin evidencia causal. No se obtienen resultados estadísticamente significativos en el caso de la renta media y mediana.

Keywords: Tasa de mortalidad; Esperanza de vida; PIB.

1. Introducción y planteamiento inicial

El objetivo de este proyecto es realizar un análisis exploratorio de datos utilizando conjuntos de datos del Instituto Nacional de Estadística (INE) sobre tasa de mortalidad, renta media y mediana por unidad de consumo e inversión en sanidad, con el propósito de encontrar patrones de asociación y evaluar si existen correlaciones entre estos indicadores socioeconómicos y de salud pública y la tasa de mortalidad en las diferentes comunidades autónomas de España. Para ello, efectuaremos una importación y limpieza o acondicionamiento de los datos, estudiaremos la presencia de datos faltantes y su posible imputación, visualizaremos gráficos exploratorios de los datos, detectaremos posibles outliers y finalmente realizaremos un análisis univariante y bivariante de las variables de cada uno de los conjuntos de datos.

2. Materiales y Métodos

2.1. Dataset renta media y mediana por C.A.

Este conjunto de datos mide en euros la renta media y mediana por unidad de consumo de la que disponen los hogares para las diferentes comunidades y ciudades autónomas de España y desde el año 2008 hasta el año 2024. Este indicador ajusta la renta del hogar según su tamaño y composición, lo que permite hacer comparaciones del bienestar económico entre comunidades autónomas así como también estudiar su distribución a lo largo del territorio español y su evolución con los años.

Citation: Carrasco, A.; Nieva, A.; Llano C. D. Tasa de mortalidad en España por comunidades autónomas. *Data* **2023**, *1*, 0. <https://doi.org/>

Received:

Revised:

Accepted:

Published:

Copyright: © 2025 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

2.1.1. Estructura y variables.

Table 1. Descripción de las variables

Variable	Descripción
Renta media y mediana	Indica si el dato corresponde a la renta media o la renta mediana por unidad de consumo.
Comunidad autónoma	Comunidad o ciudad autónoma a la que pertenece el dato (incluye el Total Nacional).
Periodo	Año al que corresponde el dato (de 2008 a 2024).
Total	Valor total de la renta media y mediana en euros por unidad de consumo.

2.1.2. Importación y acondicionamiento de los datos

Investiguemos este nuevo dataset. Veamos en primer lugar su estructura utilizando la función `glimpse()`.

```
Rows: 680
Columns: 4
$ 'Renta media y mediana' <chr> "Renta media por unidad de consumo", "Rent~
$ 'Comunidad autónoma' <chr> "Total Nacional", "Total Nacional", "Total~
$ Periodo <dbl> 2024, 2023, 2022, 2021, 2020, 2019, 2018, ~
$ Total <dbl> 21759, 20676, 19160, 18103, 18116, 17287, ~
```

Por tanto, tenemos 680 registros sobre 4 variables diferentes. Utilizando la función `unique()` para encontrar los valores únicos de cada variable. Podemos observar que la columna `Renta media y mediana` tan solo toma dos valores, pero la hemos importado como vector de caracteres. Deberíamos transformarla a factor para ahorrar espacio en memoria. De igual forma, deberíamos pasar la columna `Periodo` a formato `Date`.

Tras realizar estos cambios, utilizando de nuevo la función `glimpse()`, vemos que el dataset `tidy` nos queda de la siguiente manera, con cada variable transformada a su tipo correspondiente.

```
Rows: 680
Columns: 4
$ 'Renta media y mediana' <fct> Renta media por unidad de consumo, Renta m~
$ 'Comunidad autónoma' <chr> "Total Nacional", "Total Nacional", "Total~
$ Periodo <date> 2024-01-01, 2023-01-01, 2022-01-01, 2021-~
$ Total <dbl> 21759, 20676, 19160, 18103, 18116, 17287, ~
```

Utilizando la función `is.na()` para detectar los valores faltantes a lo largo del dataset y la función `sum()` para contarlos, comprobamos que tenemos 0 datos faltantes en este dataset.

2.1.3. Gráficos exploratorios

Realicemos un gráfico exploratorio de los datos con los que estamos trabajando. Lo haremos para el total nacional.




Figure 1. Renta media y mediana para el Total Nacional en el periodo 2008-2024.

Observamos una clara tendencia creciente en los últimos años, con dos descensos señalados: uno durante la crisis económica española de los años 2008 a 2014 y otro tras la pandemia de covid-19.

La subida a partir de 2021 es probablemente debida al crecimiento del empleo, la subida del Salario Mínimo Interprofesional y el incremento general de los salarios y revalorización de las pensiones. No obstante, todos estos valores deben interpretarse teniendo en cuenta el contexto de inflación descontrolada que experimentó España en 2022.

2.1.4. Detección outliers

Para abordar la detección de posibles outliers en nuestro conjunto de datos, utilizamos la regla del boxplot. Escogemos esta técnica ya que no es muy agresiva, y los datos de renta pueden variar bastante entre comunidades autónomas (debido, por ejemplo, al nivel de urbanización de las mismas).




Figure 2. Boxplots renta media y mediana en las diferentes comunidades autónomas para cada año.

Visualmente, no detectamos outliers en ningún año.

2.2. Dataset del PIB por agregado.

Este conjunto de datos recoge, para cada rama de actividad de la economía española y para cada año (1995-2024), los principales agregados de oferta, empleo y rentas que publica la Contabilidad Nacional anual. Es decir: cuánto produce cada rama, qué valor añadido genera, qué consume, cuánto paga en salarios, cuánto excedente obtiene y cuánta gente ocupa.

Las variables que nos interesan del dataset son las siguientes

2.2.1. Estructura y variables.

Table 2. Descripción de las variables del conjunto de datos

Variable	Descripción
Nombre_64	Rama de actividad económica según la clasificación de 64 ramas que usa el INE.
Periodo	Año de referencia de la contabilidad nacional anual (1995-2023).
Total	Valor del agregado económico para esa rama y ese año.
Agregados	Nombre del agregado económico

2.2.2. Importación y acondicionamiento de los datos.

Tras importar el dataset y realizar las operaciones necesarias en él: Eliminar las columnas que no nos interesan, quedarnos solo con la actividad relacionada con la sanidad, modificar nombres de variables y el formato de la fecha para que sea de tipo Date y coincida con el formato de la fecha del resto de dataframes, nos queda un dataset con esta estructura:

```
Rows: 240
Columns: 4
$ Nombre_64 <chr> "Actividades sanitarias", "Actividades sanitarias", "Act~
$ Año <date> 2024-01-01, 2023-01-01, 2022-01-01, 2021-01-01, 2020-01~
$ Total <dbl> NA, 110456, 103586, 100236, 92717, 88440, 83306, 81392, ~
$ Agregados <chr> "Producción", "Producción", "Producción", "Producción", ~
```

2.2.3. Imputación de datos

El porcentaje de de valores faltantes del dataframe resultante es 0.8333333%,
La distribución por columnas es la siguiente:

```
Nombre_64      Año      Total Agregados
0.000000  0.000000  3.333333  0.000000
```

La columna donde se concentran los datos faltantes es la de Total.

```
# A tibble: 1 x 2
  Año      prop_NA
<date>    <dbl>
1 2024-01-01      1
```

Se observa que todos se concentran en el año 2024. Al ser la finalidad de este dataset el relacionarlo con el dataset de mortalidad (que se explicará más adelante) y al tener solo registro hasta el año 2023, podemos permitirnos eliminar las observaciones del año 2024.

El porcentaje de de valores faltantes del dataframe resultante es 0%.

2.2.4. Detección de outliers

Para detectar los outliers, nos centramos en las Actividades Sanitarias, pues para nuestro estudio lo que nos interesa es esta categoría. Calculando sus valores intercuartílicos (IQR), se determinarán los valores que se considerarían outliers (regla del boxplot).

--- Límites del IQR para 'Actividades Sanitarias' ---

Límite Inferior ($Q1 - 1.5 \cdot IQR$): -38,260 Euros

Límite Superior ($Q3 + 1.5 \cdot IQR$): 84,065 Euros

Vemos que los outliers que hemos encontrados son los que están en el agregado de Producción y corresponde con el periodo del 2022-2024. Posiblemente a consecuencia del COVID se hizo una inversión mayor en sanidad.

2.3. Dataset de mortalidad respecto al sexo, C.A. y rango de edad

En este conjunto de datos del Instituto Nacional de Estadística (INE) se recogen varias series o funciones biométricas por rango de edad, sexo y Comunidad Autónoma —como el riesgo de fallecer, el número de supervivientes o la esperanza de vida— que se elaboran con la finalidad principal de medir cómo incide la mortalidad en una población sin que afecte la distribución por edades que tenga. De este modo, es posible comparar y estudiar en el tiempo y entre distintos lugares la evolución de este fenómeno demográfico.

2.3.1. Estructura y variables.

El dataset cuenta con estas variables:

Table 3. Descripción de las variables del conjunto de datos

Variable	Descripción
Comunidad	Comunidad autónoma a la que pertenece el registro.
Sexo	Sexo de la población (Hombres/Mujeres).
Rango_Edad	Grupo o intervalo de edad al que se refiere la medida (0 años, 1–4 años, ...).
Año	Año de referencia de la tabla de mortalidad.
Tasa_mortalidad	Tasa de mortalidad observada para ese sexo, edad y comunidad expresada en tanto por mil.
Promedio_anos_vividos	Número medio de años vividos dentro del intervalo de edad por quienes mueren en él.
Riesgo_muerte	Probabilidad de morir dentro del intervalo de edad expresado en tanto por mil.
Supervivientes	Número de personas que alcanzan ese intervalo de edad en la población hipotética.
Defunciones_teoricas	Número de defunciones esperadas en ese intervalo de edad.
Poblacion_estacionaria	Población estacionaria asociada al intervalo de edad.
Esperanza_de_vida	Esperanza de vida restante al inicio del intervalo de edad.

Las variables en las que nos vamos a centrar son la tasa de mortalidad y la esperanza de vida.

2.3.2. Importación y acondicionamiento de los datos.

Tras descargar el archivo .xlsx realizamos varias operaciones para ordenarlo, en las que se incluyen: quitar filas y columnas inútiles, cambiar el nombre de las columnas y pasar el data frame a formato tidy. Una vez tenemos el dataframe, analizamos la estructura de este (*str()*), y nos damos cuenta que todas las variables son de tipo *char*, por lo que las modificamos para que la variable Año sea de tipo *Date*, Rango_Edad sea de tipo *factor*, y las variables numéricas de tipo *numeric*.

Rows: 25,536

Columns: 13

```

$ ...1          <chr> "1", "2", "3", "4", "5", "6", "7", "8", "9"~ 142
$ ...2          <chr> "1", "2", "3", "4", "5", "6", "7", "8", "9"~ 143
$ Comunidad     <chr> "Andalucía", "Andalucía", "Andalucía", "And~ 144
$ Sexo          <chr> "Hombres", "Hombres", "Hombres", "Hombres",~ 145
$ Rango_Edad    <fct> 0 años, 0 años, 0 años, 0 años, De 1 a 4 añ~ 146
$ Año           <date> 2003-01-01, 2002-01-01, 2001-01-01, 2000-0~ 147
$ Tasa_mortalidad <dbl> 5.064763, 5.224284, 4.671550, 5.149879, 0.3~ 148
$ Promedio_anos_vividos <dbl> 0.109289, 0.111932, 0.100939, 0.108430, 0.3~ 149
$ Riesgo_muerte <dbl> 5.042017, 5.200158, 4.652012, 5.126342, 1.4~ 150
$ Supervivientes <dbl> 100000.00, 100000.00, 100000.00, 100000.00,~ 151
$ Defunciones_teoricas <dbl> 504.20168, 520.01582, 465.20119, 512.63416,~ 152
$ Poblacion_estacionaria <dbl> 99550.90, 99538.19, 99581.76, 99542.95, 397~ 153
$ Esperanza_de_vida <dbl> 75.12557, 75.20622, 75.19828, 74.91730, 74.~ 154

```

2.3.3. Imputación de datos.

Para saber que realizar con los valores faltantes, primero vamos a realizar un análisis del data frame.

Vemos que este data frame tiene un 0.5398111% de valores faltantes, un valor muy bajo. Si vemos el porcentaje de los datos faltantes por columnas obtenemos el siguiente resultado:

...1	...2	Comunidad
0.000000	0.000000	0.000000
Sexo	Rango_Edad	Año
0.000000	0.000000	0.000000
Tasa_mortalidad	Promedio_anos_vividos	Riesgo_muerte
1.002506	1.002506	1.002506
Supervivientes	Defunciones_teoricas	Poblacion_estacionaria
1.002506	1.002506	1.002506
Esperanza_de_vida		
1.002506		

Se observa que los datos faltantes son de las variables numéricas, y además, faltan en la misma proporción, lo que nos puede indicar que no hay aleatoriedad.

A continuación vamos a realizar una observación de los datos faltantes respecto a las variables categóricas en busca de patrones. Al sacar los datos faltantes en función de las variables categóricas, se observa que estamos ante un claro caso de datos faltantes no al azar (MNAR). Las observaciones faltantes corresponden con personas que sobrepasan los 90 años, lo que indica que no hay datos reales para esos casos. En este caso se ha decidido no imputar estos datos, ya que no contamos con ninguna base empírica para estimar los valores de las variables de esas edades.

Como la mayoría de los datos faltantes pertenecen al rango de edad de 90 y más años y al tener otros rangos de edad que comprenden también ese rango, hemos decidido eliminar esas observaciones.

```

# A tibble: 3 x 3 143
  Rango_Edad      prop_NA porcentaje_NA 144
  <fct>          <dbl>         <dbl> 145
1 De 90 a 94 años  0.105           10.5 146
2 De 95 y más años 0.105           10.5 147
3 0 años          0              0    148

```

Ahora el data frame cuenta con un 0.5398111% de datos faltantes, un valor muy bajo. El resto de NAs al ser tan pocos, y centrados solo en tres Comunidades Autonomas, hemos decidido dejarlos y realizar los cálculos de los estadísticos obviándolos.

2.3.4. Detección de outliers

192

Para detectar outliers vamos a aplicar los 3 métodos siguientes:

193

- **Regla 3 sigma:** Esperanza de vida 0 y tasa de mortalidad 906.
 - **Identificador de Hampel:** Esperanza de vida 0 y tasa de mortalidad 0.
 - **Regla boxplot:** Esperanza de vida 0 y tasa de mortalidad 4492.
- 194195196

Los valores tan elevados en la tasa de mortalidad con **Sigma 3** y **Boxplot** se debe a que lo máximo de la tasa de mortalidad está en De 95 y más años, donde llega a ~923 por mil, y en edades muy altas también sube mucho. Eso es exactamente lo que debe pasar: la mortalidad crece exponencialmente con la edad. No es un outlier, es la realidad de ese grupo.

197198199200201

El valor 0 en la tasa de mortalidad con **Hampel** es 0 ya que usa la mediana y el MAD, que apenas se mueven aunque haya valores muy grandes, así que los extremos no arrastran el criterio como sí pasa con la media y la desviación típica.

202203204

3. Resultados

205

3.1. Análisis univariante y bivalente

206

Para responder algunas cuestiones que nos hemos planteado, vamos a realizar un análisis univariante y bivalente de las variables que nos interesan:

207208

3.1.1. ¿Cuál es la esperanza de vida media en España en el último año disponible? ¿Qué Comunidad Autónoma es la que más tiene, y la que menos?

209210

Para este análisis de la esperanza de vida se ha escogido calcular la media para una edad de 0 años.

211212

La media de esperanza de vida en España del año 2023 (Último año disponible) es de 83.466.

213214




Figure 3. Esperanza de vida media por C.A. en 2023 .

Podemos observar que la media de esperanza de vida más alta en españa pertenece a La Comunidad de Madrid mientras que la que menos esperanza de vida tiene es Ceuta con una diferencia de 4.108 años.

215216217

3.1.2. ¿Cual es la evolución de la esperanza de vida en el tiempo?

218




Figure 4. Evolución de la esperanza de vida (1992-2023).

Se puede apreciar una caída de la esperanza de vida en el año 2020, que coincide exactamente con la pandemia de COVID-19:

219

220




Figure 5. Evolución de la esperanza de vida (2019-2023).

Durante el COVID, la disminución media de la esperanza de vida fue de:1.067

221

3.1.3. ¿Cómo evoluciona la esperanza de vida y la tasa de muerte en función al rango de edad?

222223




Figure 6. Esperanza de vida y tasa de mortalidad en función de la edad

En esta gráfica se puede observar que a partir del rango de edad de 50 a 54 años el crecimiento de la tasa de mortalidad es exponencial, debido al aumento de los problemas de salud que hay a altas edades. También se aprecia que con 0 años la tasa de mortalidad es algo más elevada que con un rango de 1 a 4 años, por el riesgo que se tiene como recién nacido.

La esperanza de vida disminuye de forma lineal aunque se pueden apreciar varias curvas leves. Esto pasa porque la mortalidad por grupos de edad no es estrictamente decreciente: hay pequeños saltos entre tramos. Esos cambios se trasladan a la esperanza de vida del tramo siguiente y generan ligeras ondulaciones. Al además suavizar con loess y reescalar la serie para ponerla en el mismo gráfico, esas variaciones quedan más visibles.

3.1.4. ¿Que relación hay entre el riesgo de muerte y la esperanza de vida?

234

Para ver la relación entre esas dos variables, se ha usado un gráfico de dispersión, pero al haber tantos puntos se optó por usar un mapa de densidad de puntos usando bind2d, que agrupa los puntos en celdas.




Figure 7. Mapa de desnsidad de la tasa de mortalidad y el riesgo de muerte

La gráfica muestra una relación claramente inversa: cuando el riesgo de muerte del tramo (qx) es muy bajo, la esperanza de vida es alta; conforme el riesgo aumenta, la esperanza de vida cae rápidamente. La mayor concentración de observaciones está en la zona de qx muy pequeños (edades jóvenes), donde casi no se muere y todavía quedan muchos años por vivir.

La celda amarilla se debe a que es donde el riesgo de muerte es 1, es decir, todo el mundo muere en ese intervalo (De 95 a más años). Como para ese tramo hay varias combinaciones (años, sexos, comunidades...), se acumulan muchos registros en la misma celda.

3.1.5. ¿Cómo se relaciona la tasa de mortalidad con el peso económico del sector sanitario?

Para ello sacamos varios gráficos de dispersión en el que relacionamos el total del PIB por agregado y la tasa de mortalidad.




Figure 8. Gráfico de dispersión de la tasa de mortalidad con los diferentes agregados del PIB

Para todos los agregados sanitarios analizados se observa una asociación negativa entre el volumen económico anual (millones de euros) y la tasa media de mortalidad: en los años en los que el sector sanitario mueve más recursos, la mortalidad media es menor. Sin embargo, no se puede obtener una conclusión clara, ya que este aumento también puede explicarse por una tendencia temporal común, por lo que no puede interpretarse directamente como una relación causal.

Para relacionar la tasa de mortalidad con el dataset de renta media y mediana por C.A. comenzaremos calculando algunos estadístico descriptivos básicos de este dataset para realizar el análisis univariante de nuestro conjunto de datos. Nos centraremos en los valores de la renta media y renta mediana para todas las comunidades autónomas (excluyendo el Total Nacional) y para todos los años.

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
11345	14973	17076	17193	19277	27537
Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
9492	12864	15134	15251	17163	25051

Realizando un análisis muy general observamos, como era de esperar, que los estadísticos calculados para valores de la renta media por unidad de consumo son siempre superiores a los correspondientes valores para la renta mediana. Es más, la media de la renta media y la media de la renta mediana son superiores a las medianas correspondientes

Esto se debe a que la mediana es más resistente a valores más altos (rentas más altas) que la media, de forma que representa mejor a la población ubicada en el centro de la distribución de rentas.

Los diagramas de cajas dibujados en el apartado anterior para la detección de outliers también nos permiten hacernos una idea, al menos visual, de la distribución de la renta media y mediana en todas las comunidades autónomas de España para cada año en el periodo de 2008 a 2024.

Podemos realizar una visualización de la distribución de la renta media y mediana mediante los siguientes histogramas.




Figure 9. Histogramas de la distribución de la renta media y mediana para todas las comunidades autónomas.




Figure 10. Histogramas de la distribución de la renta media y mediana para todas las comunidades autónomas.

3.1.6. ¿Existe relación entre la tasa de mortalidad y la renta media y mediana por unidad de consumo?

Para tratar de responder a esta pregunta, realizamos un `inner_join()` entre los datasets de renta media y mediana por unidad de consumo y tasa de mortalidad, quedándonos únicamente con los registros que coinciden en Comunidad Autónoma y Periodo para ambos.

Para analizar la posible relación existente entre las variables de renta media y mediana y la tasa de mortalidad por comunidades autónomas, promediamos en primer lugar los datos a lo largo de todos los años disponibles.

Podemos visualizar la relación estudiada con los siguientes gráficos de dispersión.




Figure 11. Diagrama de dispersión de la renta media y tasa de mortalidad para cada comunidad autónoma.




Figure 12. Diagrama de dispersión de la renta mediana y tasa de mortalidad para cada comunidad autónoma.

Visualmente, percibimos una ausencia de correlación entre la renta media y mediana promedio y la tasa de mortalidad por comunidades autónomas. No obstante, para verificar estas intuiciones matemáticamente, haremos un test de correlación estimando el coeficiente de correlación de Pearson y el de Spearman.

Obtenemos para la renta media un coeficiente de correlación de Pearson de -0.0911912 y una correlación de Spearman de -0.3929825. Por otra parte, para la renta mediana, el coeficiente de Pearson es de 0.0377603 y el Spearman de -0.3087719.

Por tanto, los resultados muestran una ausencia de correlación lineal (Pearson) entre la renta (tanto media y mediana) y la tasa de mortalidad. Sin embargo, la correlación de Spearman muestra una cierta relación negativa débil, siendo $\rho = -0.356$ para la renta media y $\rho = -0.272$ para la renta mediana. Ahora bien, al revisar los p-valores (0.0970259

y 0.1979246, respectivamente) verificamos que estos coeficientes no son estadísticamente signativos.

4. Conclusiones finales

Con este análisis podemos ver que la mortalidad y la esperanza de vida en españa presentan un patrón estable territorialmente. Algunas comunidades mantienen sistemáticamente mejores indicadores, mientras que otras se sitúan en la parte baja. Sucesos como el COVID-19 han afectado notablemente a estos datos. La exploración con información económica apunta a una relación compatible con “más recursos sanitarios, menor mortalidad”, pero el diseño descriptivo y la presencia de tendencias temporales comunes impiden afirmar causalidad. Futuros trabajos deberían cruzar renta y mortalidad por comunidad y año, incorporar variables demográficas de control y aplicar modelos que separen efectos de tiempo y territorio para afinar estas conclusiones.

Funding: This research received no external funding.

Data Availability Statement: Todos los conjuntos de datos han sido obtenidos de la página del Instituto Nacional de Estadística (INE) (<https://www.ine.es/>). Son los siguientes:

- Indicadores de renta media y mediana
- Renta media y mediana por comunidad autónoma
- Mortalidad por año, comunidades y ciudades autónomas, sexo y edad.
- Cuentas nacionales. Principales agregados del PIB

Conflicts of Interest: The authors declare no conflict of interest. The founding sponsors had no role in the design of the study; in the collection, analyses, or interpretation of data; in the writing of the manuscript, an in the decision to publish the results

Abbreviations

The following abbreviations are used in this manuscript:

- INE Instituto Nacional de Estadística
- MNAR Missing Not At Random

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.